

TÍTULO DE LA INVESTIGACIÓN

**“Modelo de analítica predictiva
espacio-temporal para patrullajes
preventivos en Lima Metropolitana”**

TRABAJO DE INVESTIGACIÓN

PRESENTADO POR:

César Jesús Dose Preciado Calderón

DNI N.º 60770855

LIMA, PERÚ

2026

DECLARACIÓN JURADA DE ORIGINALIDAD

Yo, César Jesús Dose Preciado Calderón, identificado con DNI N.º 60770855, autor del presente trabajo de investigación, declaro bajo juramento que:

- a) Soy el autor del documento académico titulado “Modelo de analítica predictiva espacio-temporal para patrullajes preventivos en Lima Metropolitana”.
- b) El trabajo de investigación es original y no ha sido difundido en ningún medio académico; por lo tanto, sus resultados son veraces y no es copia de ningún otro.
- c) El trabajo incluye citas a otros autores y referencias bibliográficas verificables, cumpliendo con las pautas académicas y las normas de citado internacional (APA).
- d) El trabajo se ha elaborado con respeto absoluto a la propiedad intelectual de terceros.
- e) Declaro conocer las consecuencias legales y/o administrativas que puedan derivarse de la falsedad total o parcial de la presente declaración.

Fecha: 05 de septiembre de 2026

Firma del autor

A mis padres, por su apoyo incondicional y por cada sacrificio que hizo posible llegar hasta aquí; este logro es tan suyo como mío.

A Ariana, mi enamorada, que me acompañó durante estos tres años de estudios y que hoy sigue acompañándome en cada paso que doy.

A Sony, mi gato, que me hizo compañía durante los tres años completos de esta carrera y que ahora descansa en paz.

— César Jesús Dose Preciado Calderón

Índice general

Resumen	7
Abstract	9
Introducción	11
1. Información general	13
1.1. Título del proyecto	13
1.2. Área estratégica de desarrollo prioritario	13
1.3. Actividad económica en la que se aplicaría la investigación	13
1.4. Localización o alcance de la solución	14
2. Descripción de la investigación	15
2.1. Planteamiento del problema	15
2.1.1. Problemas de investigación	16
2.2. Justificación	17
2.2.1. Justificación teórica	17
2.2.2. Justificación metodológica	18
2.2.3. Justificación práctica	18
2.3. Marco referencial	19
2.3.1. Antecedentes de investigación	19
2.3.2. Marco teórico	21
2.3.3. Glosario de términos	24
2.4. Resumen ejecutivo	25
2.5. Objetivos general y específicos: propósito del proyecto	25
2.5.1. Objetivo general	25
2.5.2. Objetivos específicos	26
2.6. Limitaciones	26
2.7. Metodología del proyecto	27

2.7.1.	Enfoque de investigación	27
2.7.2.	Tipo de investigación	27
2.7.3.	Diseño de investigación	27
2.7.4.	Fuentes y técnicas de recolección de datos	28
2.7.5.	Población y unidad de análisis	28
2.7.6.	Metodología para el componente analítico-predictivo (CRISP-DM) .	28
2.7.7.	Cronograma referencial de la investigación	29
2.7.8.	Arquitectura tecnológica de referencia propuesta	30
2.7.9.	Validez y confiabilidad	31
2.7.10.	Consideraciones éticas	31
3.	Resultado de la investigación	32
3.1.	Descripción y preparación del conjunto de datos	32
3.2.	Análisis espacial: mapas de calor	33
3.3.	Modelo predictivo espacio-temporal	34
3.4.	Arquitectura de referencia del sistema	35
3.5.	Validación cualitativa con usuarios potenciales	35
3.6.	Discusión de resultados	35
4.	Conclusiones y recomendaciones	37
4.1.	Conclusiones	37
4.1.1.	Conclusiones respecto al objetivo general	37
4.1.2.	Conclusiones respecto a los objetivos específicos	37
4.2.	Recomendaciones	38
	Referencias bibliográficas	40
	Anexos	43

Índice de tablas

3.1. Resumen del conjunto de datos final	33
3.2. Comparativa de desempeño de los modelos evaluados	34

Índice de figuras

2.1. Mapa de calor conceptual	22
2.2. Estimación de densidad de kernel (KDE)	22
2.3. Ciclo de vida CRISP-DM	29
2.4. Cronograma referencial de la investigación	30
2.5. Arquitectura tecnológica de referencia	31

Resumen

La inseguridad ciudadana y la siniestralidad vial constituyen dos de los problemas públicos más apremiantes del Perú, y en particular de Lima Metropolitana, donde la percepción de inseguridad supera el 90 % de la población y se registran miles de siniestros de tránsito cada año ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#); [Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)). A pesar de la existencia de plataformas de datos abiertos –como el Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana del INEI y el Observatorio Nacional de Seguridad Vial del MTC–, estas fuentes suelen analizarse de forma aislada y descriptiva, sin integrarse en una herramienta única que permita anticipar dónde y cuándo es más probable que ocurran hechos delictivos o accidentes de tránsito, y que oriente así la programación de los patrullajes preventivos.

El presente trabajo de investigación propone, por un lado, el diseño y la validación experimental de un modelo de analítica predictiva espacio-temporal –basado en mapas de calor (análisis de puntos calientes o *hotspots*) mediante estimación de densidad de kernel (*Kernel Density Estimation*, KDE) y en algoritmos de aprendizaje automático– que estima la probabilidad relativa de ocurrencia de hechos delictivos y accidentes por zona, día y franja horaria; y, por otro lado, la definición de una arquitectura de referencia para un Sistema de Información Geográfica (SIG), dejando abierto el desarrollo de la aplicación a futuros equipos de software. El modelo tiene como propósito generar recomendaciones de horarios y sectores priorizados para el patrullaje preventivo, apoyando la toma de decisiones operativas de las comisarías, del serenazgo municipal y de las áreas de gestión vial; asimismo, sus mapas de riesgo resultan de interés para el sector asegurador, al permitir identificar zonas y franjas horarias de mayor siniestralidad con fines de prevención y tarificación.

Metodológicamente, la investigación es de tipo aplicada, con un enfoque cuantitativo, diseño no experimental, y sigue la metodología CRISP-DM ([Chapman et al., 2000](#)) para el ciclo de vida del componente analítico-predictivo. La validación del modelo se realiza mediante simulación sobre datos históricos (validación cruzada temporal o *backtesting*)

construidos a partir de fuentes de datos abiertos, en lugar del desarrollo de un prototipo operativo. Para orientar el futuro desarrollo de software, se propone una arquitectura tecnológica de referencia basada en herramientas de código abierto: PostgreSQL/PostGIS como motor de base de datos espacial ([PostGIS Project Steering Committee, 2024](#)), Python para el procesamiento y modelado de datos, y bibliotecas de visualización web (Leaflet) para la capa de presentación cartográfica.

Se espera que el modelo validado y la arquitectura de referencia constituyan instrumentos replicables de bajo costo para gobiernos locales, comisarías y aseguradoras del Perú, contribuyendo a una gestión de la seguridad ciudadana y vial basada en evidencia, y dejando establecida la base para el desarrollo posterior del sistema.

Palabras clave: analítica predictiva espacio-temporal, criminalidad, siniestralidad vial, patrullaje preventivo, datos abiertos, mapas de calor, arquitectura de referencia.

Abstract

Citizen insecurity and road traffic accidents are two of the most pressing public problems in Peru, particularly in Metropolitan Lima, where perceived insecurity exceeds 90 % of the population and thousands of traffic incidents are recorded every year ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#); [Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)). Although open data platforms exist –such as INEI’s Integrated Crime and Citizen Security Statistics System and the Ministry of Transport’s National Road Safety Observatory– these sources are usually analyzed in isolation and descriptively, without being integrated into a single tool capable of anticipating where and when criminal incidents or traffic accidents are more likely to occur, in order to guide preventive patrol scheduling.

This research proposes, on the one hand, the design and experimental validation of a spatio-temporal predictive analytics model –based on hotspot maps through Kernel Density Estimation (KDE) and machine learning algorithms– that estimates the relative probability of criminal incidents and accidents by zone, day, and time slot; and, on the other hand, the definition of a reference architecture for a Geographic Information System (GIS), leaving the application’s development open to future software teams. The model aims to generate schedule and priority-zone recommendations for preventive patrolling, supporting operational decision-making by police stations, municipal citizen-security units and road-safety managers. Its risk maps are also of interest to the insurance sector, as they identify zones and time slots with higher accident rates for prevention and pricing purposes.

Methodologically, this is an applied, quantitative, non-experimental study that follows the CRISP-DM methodology ([Chapman et al., 2000](#)) for the analytics lifecycle. The model is validated through simulation on historical data (temporal cross-validation, i.e., backtesting) built from open data sources, rather than through the development of an operational prototype. To guide future software development, a reference technology architecture based on open-source tools is proposed: PostgreSQL/PostGIS as the spatial database engine ([PostGIS Project Steering Committee, 2024](#)), Python for data processing and modeling, and web mapping libraries (Leaflet) for the presentation layer.

The validated model and the reference architecture are expected to become low-cost, replicable tools for Peruvian local governments, police stations and insurance companies, contributing to evidence-based management of citizen and road safety, and laying the groundwork for the subsequent development of the system.

Keywords: spatio-temporal predictive analytics, crime, road safety, preventive patrolling, open data, hotspot maps, reference architecture.

Introducción

La seguridad ciudadana es, de manera sostenida, uno de los principales problemas públicos percibidos por la población peruana. De acuerdo con el Instituto Nacional de Estadística e Informática (INEI), la percepción de inseguridad ciudadana en Lima Metropolitana se ha mantenido por encima del 88 % durante los últimos años, mientras que la tasa de victimización –pese a fluctuaciones– continúa siendo elevada ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#)). De manera paralela, la siniestralidad vial representa otra fuente crítica de pérdida de vidas humanas: el Ministerio de Transportes y Comunicaciones (MTC), a través de su Observatorio Nacional de Seguridad Vial, reporta que en el Perú fallecen en promedio más de 260 personas al mes a causa de accidentes de tránsito, con Lima como la región de mayor incidencia absoluta ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)).

Ambos fenómenos –criminalidad y siniestralidad vial– comparten una característica que resulta clave para su abordaje tecnológico: no se distribuyen de manera uniforme en el espacio ni en el tiempo, sino que se concentran en determinadas zonas (*hotspots*) y franjas horarias, un hallazgo ampliamente documentado en la literatura de análisis criminal y de seguridad vial ([Eck et al., 2005](#); [Chainey et al., 2008](#)). Esta concentración espacio-temporal es precisamente lo que permite que los Sistemas de Información Geográfica (SIG), combinados con técnicas de analítica predictiva, puedan aportar valor concreto a la planificación del patrullaje preventivo, en la medida en que permiten estimar dónde y cuándo es más probable que ocurra un hecho delictivo o un accidente, y priorizar en consecuencia los recursos disponibles.

En el contexto peruano, diversas iniciativas gubernamentales y académicas han abordado de forma parcial este problema. El INEI, en colaboración con el Banco Interamericano de Desarrollo, implementó el Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana, que georreferencia denuncias a nivel de comisaría e incluso de manzana ([Banco Interamericano de Desarrollo \[BID\], 2020](#)). A nivel de investigación de posgrado, se han desarrollado propuestas como un sistema de geolocalización con componentes predictivos básicos para la prevención del crimen urbano en el Callao ([Talla De La Cruz et al.,](#)

2025), un tablero de control para el patrullaje motorizado policial en Lima Metropolitana (Sánchez Ramírez and Guevara Bazán, 2022), y una solución de inteligencia de negocios para el patrullaje integrado PNP-Serenazgo en Tarapoto (Flores Flores, 2017). Sin embargo, ninguna de estas iniciativas integra, en un único modelo de analítica predictiva, datos abiertos de criminalidad y de siniestralidad vial orientado específicamente a recomendar horarios y sectores de patrullaje, ni aporta una arquitectura de referencia que facilite el desarrollo posterior del software.

En este contexto, la presente investigación tiene como objetivo diseñar y validar, a partir de fuentes de datos abiertos, un modelo de analítica predictiva espacio-temporal que permita identificar patrones espaciales y temporales de criminalidad y siniestralidad vial en Lima Metropolitana, y generar recomendaciones para la planificación de patrullajes preventivos, dejando además definida una arquitectura de referencia para el desarrollo posterior del correspondiente Sistema de Información Geográfica.

El documento se organiza de la siguiente manera: el Capítulo I presenta la información general del proyecto. El Capítulo II desarrolla la descripción de la investigación: el planteamiento del problema, la justificación, el marco referencial (antecedentes, marco teórico y glosario), los objetivos, las limitaciones y la metodología del proyecto. El Capítulo III expone los resultados de la investigación (análisis de datos y validación del modelo predictivo mediante simulación). Finalmente, el Capítulo IV presenta las conclusiones y recomendaciones, seguido de las referencias bibliográficas y los anexos.

Capítulo 1

Información general

1.1. Título del proyecto

Modelo de analítica predictiva espacio-temporal para patrullajes preventivos en Lima Metropolitana.

1.2. Área estratégica de desarrollo prioritario

El presente proyecto se ubica en el ámbito de las Tecnologías de la Información y la Comunicación (TIC) aplicadas a la gestión de la seguridad ciudadana y la seguridad vial, específicamente en el campo de los Sistemas de Información Geográfica (SIG) y la ciencia de datos aplicada (analítica predictiva y aprendizaje automático). Esta área es priorizada de manera explícita por la Política Nacional de Transformación Digital y por la Política Nacional Multisectorial de Seguridad Ciudadana al 2030, que promueven el uso de tecnologías emergentes para el fortalecimiento de la seguridad y el bienestar ciudadano (Talla De La Cruz et al., 2025).

1.3. Actividad económica en la que se aplicaría la investigación

El proyecto se enmarca en el sector de servicios de tecnología de la información (desarrollo de software) aplicado al sector público, particularmente a las entidades responsables de la seguridad ciudadana (Policía Nacional del Perú, gerencias de seguridad ciudadana y serenazgo de los gobiernos locales) y de la seguridad vial (Ministerio de Transportes y Comunicaciones, Autoridad de Transporte Urbano para Lima y Callao – ATU). El sistema

propuesto se orienta a la mejora de procesos de gestión pública mediante el aprovechamiento de datos abiertos, en línea con la línea de investigación institucional de Mejora de Procesos y con la línea de Gobierno Digital.

1.4. Localización o alcance de la solución

El ámbito geográfico de aplicación de la propuesta es Lima Metropolitana, Perú.

Los resultados del modelo están orientados a ser usados por: (i) personal de comisarías y áreas de planeamiento operativo de la Policía Nacional del Perú; (ii) gerencias de seguridad ciudadana y centrales de serenazgo de municipalidades distritales; (iii) tomadores de decisión en materia de seguridad vial a nivel municipal y metropolitano; y (iv) aseguradoras y empresas del sector seguros, para quienes los mapas de riesgo de siniestralidad por zona y franja horaria constituyen un insumo valioso para la evaluación, la prevención y la tarificación de riesgos. La motivación práctica del proyecto radica en que la incorporación de análisis espacial y predictivo en la planificación operativa reduce la dependencia de la experiencia individual o de criterios empíricos no sistematizados, aportando evidencia cuantitativa para la toma de decisiones ([Eck et al., 2005](#)).

Capítulo 2

Descripción de la investigación

2.1. Planteamiento del problema

La inseguridad ciudadana en el Perú, y en particular en Lima Metropolitana, se mantiene como uno de los principales problemas públicos percibidos por la población. Según cifras del INEI, entre el periodo julio-diciembre de 2020 y el mismo periodo de 2021, la percepción de inseguridad ciudadana en Lima Metropolitana se incrementó de 89.7 % a 92.9 %, a pesar de que la tasa de victimización efectiva descendió de 26.8 % a 22.3 % en el mismo lapso ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#)). Esta aparente contradicción –menor victimización pero mayor percepción de inseguridad– evidencia que la gestión de la seguridad ciudadana no puede sustentarse únicamente en indicadores agregados anuales, sino que requiere de herramientas que permitan comunicar y accionar sobre patrones espaciales y temporales concretos, visibles y comprensibles tanto para los tomadores de decisión como, eventualmente, para la ciudadanía.

De manera paralela, la siniestralidad vial constituye un problema de salud pública de magnitud comparable. El MTC reporta que en el Perú fallecen aproximadamente 12 personas al día por accidentes de tránsito, con Lima concentrando la mayor cantidad absoluta de siniestros a nivel nacional (35 354 eventos en un periodo reciente de análisis, muy por encima de Arequipa o La Libertad) ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)). Al igual que en el caso de la criminalidad, la ocurrencia de siniestros viales no es aleatoria: se concentra en determinados corredores viales, intersecciones, horarios (de manera notoria en la madrugada y en horas de baja visibilidad) y tipos de vía.

Pese a la existencia de fuentes de datos abiertos relevantes –como el Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana del INEI ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#)) y el Observatorio Nacional de Seguridad Vial del MTC ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#))–, se identifican

al menos tres brechas relevantes para la gestión operativa de la seguridad:

1. **Fragmentación de fuentes.** Los datos de criminalidad y de siniestralidad vial se publican en plataformas independientes, con formatos, niveles de agregación geográfica y periodicidades distintas, lo que dificulta su análisis conjunto por parte de comisarías o gerencias municipales de seguridad ciudadana, que rara vez cuentan con personal especializado en ciencia de datos.
2. **Enfoque descriptivo y no predictivo.** La mayor parte de las herramientas disponibles –incluyendo experiencias nacionales documentadas, como el Tablero de Control de Calidad del Patrullaje (TABCOP) (Sánchez Ramírez and Guevara Bazán, 2022)– se centran en visualizar indicadores históricos (lo ocurrido), pero no incorporan un componente de estimación de probabilidad futura que oriente explícitamente dónde y cuándo priorizar el patrullaje.
3. **Desarticulación entre el mapa del delito y la programación operativa.** Investigaciones previas en el contexto peruano han identificado que la ausencia de una metodología única y sistematizada de georreferenciación dificulta la elaboración de mapas del delito comparables entre comisarías, y que la coordinación entre la Dirección de Estadística de la PNP y las comisarías para el manejo uniforme de esta información es limitada (Mora Luque, 2015). De manera similar, se ha documentado que la deficiente programación y seguimiento del patrullaje motorizado por sector es una de las causas más influyentes de su baja calidad en Lima Metropolitana (Sánchez Ramírez and Guevara Bazán, 2022).

En consecuencia, se identifica la necesidad de un modelo de analítica predictiva que integre datos abiertos de criminalidad y de siniestralidad vial, capaz de generar mapas de calor y estimaciones de probabilidad espacio-temporal que sirvan como insumo objetivo para la programación de patrullajes preventivos, así como de una arquitectura de referencia que oriente el posterior desarrollo del correspondiente Sistema de Información Geográfica.

2.1.1. Problemas de investigación

Problema general

¿En qué medida un modelo de analítica predictiva espacio-temporal, construido sobre datos abiertos de criminalidad y siniestralidad vial, permite estimar las zonas y franjas horarias de mayor riesgo para apoyar la planificación de patrullajes preventivos en Lima Metropolitana?

Problemas específicos

- PE1: ¿Cómo se distribuyen espacial y temporalmente los hechos delictivos y los siniestros de tránsito registrados en las fuentes de datos abiertos disponibles para Lima Metropolitana?
- PE2: ¿Qué técnicas de análisis espacial y de aprendizaje automático permiten estimar con mayor precisión las zonas y franjas horarias de mayor probabilidad de ocurrencia de hechos delictivos y siniestros viales?
- PE3: ¿Qué arquitectura de referencia, basada en componentes de código abierto, permitiría integrar en un futuro Sistema de Información Geográfica web los componentes de recolección de datos, modelado predictivo y visualización cartográfica?
- PE4: ¿En qué medida las recomendaciones generadas por el modelo (sectores y horarios priorizados) son consistentes con los patrones históricos observados en los datos de validación?

2.2. Justificación

2.2.1. Justificación teórica

La presente investigación se sustenta en el cuerpo teórico de la criminología ambiental y del análisis espacial del delito, que sostiene que el comportamiento delictivo no se distribuye de manera aleatoria en el territorio, sino que se concentra en función de oportunidades, rutinas y características del entorno construido (Eck et al., 2005). Bajo este marco, técnicas como la estimación de densidad de kernel (KDE) han demostrado utilidad empírica para predecir patrones espaciales futuros de criminalidad a partir de la concentración histórica de eventos (Chainey et al., 2008). De manera complementaria, la literatura sobre *predictive policing* ha explorado modelos de procesos puntuales autoexcitados, en los que la ocurrencia de un delito incrementa temporalmente la probabilidad de delitos similares en su vecindad espacial y temporal (Mohler et al., 2011), así como marcos de referencia más amplios sobre el rol de la predicción del delito en las operaciones policiales (Perry et al., 2013). Esta investigación traslada dichos marcos conceptuales, ampliamente aplicados en contextos internacionales, al análisis conjunto e inédito de criminalidad y siniestralidad vial con datos abiertos peruanos.

2.2.2. Justificación metodológica

Se optó por un enfoque cuantitativo y aplicado, apoyado en la metodología CRISP-DM (Chapman et al., 2000), ampliamente validada en la industria, para estructurar el ciclo de vida del componente analítico-predictivo (comprensión del negocio, comprensión y preparación de los datos, modelado, evaluación y despliegue). Esta metodología resulta especialmente adecuada para un proyecto de alcance acotado como una tesina técnica, porque garantiza el rigor en el tratamiento estadístico y geoespacial de los datos y permite validar el modelo mediante simulación sobre datos históricos (validación cruzada temporal o *backtesting*), sin requerir el desarrollo de un sistema operativo; el desarrollo del software queda orientado por la arquitectura de referencia propuesta y planteado como línea de trabajo futura.

2.2.3. Justificación práctica

En el plano práctico, la investigación se justifica porque aporta un modelo validado y reproducible, construido íntegramente con datos abiertos y herramientas de código abierto, que puede ser adoptado sin costos de licenciamiento por comisarías, gobiernos locales y aseguradoras con recursos presupuestales limitados. Investigaciones nacionales previas han evidenciado que la deficiente programación del patrullaje motorizado por sector es una de las causas más relevantes de su baja calidad en Lima Metropolitana (Sánchez Ramírez and Guevara Bazán, 2022), y que experiencias comparadas –como el Plan Nacional de Vigilancia Comunitaria por Cuadrantes de Colombia o el Plan Cuadrante de Seguridad Preventiva de Carabineros de Chile– han mostrado mejoras operativas relevantes al introducir criterios sistemáticos de sectorización y análisis espacio-temporal en la planificación policial. En este sentido, el modelo propuesto busca aportar evidencia cuantitativa directamente utilizable para la reducción de la deficiente programación del patrullaje identificada como causa crítica en la literatura nacional, sumar por primera vez la dimensión de siniestralidad vial a este tipo de análisis y ofrecer, además, un insumo objetivo para la evaluación de riesgos por parte del sector asegurador.

2.3. Marco referencial

2.3.1. Antecedentes de investigación

Internacionales

[Chainey et al. \(2008\)](#) evaluaron la utilidad predictiva de distintas técnicas de mapeo de puntos calientes (*hotspot mapping*), incluyendo la estimación de densidad de kernel, para anticipar la ubicación futura de delitos en Londres. Su metodología comparó el desempeño predictivo de cinco técnicas distintas de análisis espacial, encontrando que el KDE ofrece un balance adecuado entre precisión predictiva y facilidad de interpretación visual para analistas no especializados, razón por la cual se ha convertido en el estándar de facto en software de mapeo delictivo policial a nivel internacional. Los autores concluyen que, si bien ninguna técnica de *hotspot mapping* logra una predicción perfecta, todas superan de manera significativa a la ausencia de análisis espacial, lo cual respalda la pertinencia de incorporar este tipo de técnicas incluso en contextos con datos limitados.

Por su parte, [Mohler et al. \(2011\)](#) propusieron un modelo de procesos puntuales autoexcitados (análogo a los modelos epidémicos de réplicas sísmicas) para representar la dinámica temporal del delito, bajo la premisa de que un hecho delictivo incrementa transitoriamente el riesgo de delitos similares en su entorno cercano (efecto de contagio o victimización repetida cercana). Este modelo sentó las bases teóricas de plataformas comerciales de *predictive policing* adoptadas posteriormente en distintas ciudades de Estados Unidos. El informe de [Perry et al. \(2013\)](#), elaborado para la RAND Corporation, sistematiza la experiencia de múltiples departamentos de policía en la adopción de herramientas predictivas, concluyendo que su valor depende críticamente de la calidad de los datos de entrada y de su integración efectiva en los procesos operativos existentes, y no únicamente de la sofisticación del modelo estadístico empleado; hallazgo que resulta especialmente relevante para el diseño de la arquitectura de datos del presente proyecto.

En el ámbito latinoamericano, [Kahn \(2019\)](#) documentó la aplicación de técnicas de cartografía criminal (SIG especializados, regresiones espaciales, superficies de probabilidad) en la investigación criminal de São Paulo, Brasil, distinguiendo entre un nivel de análisis operativo-táctico (de uso cotidiano por unidades policiales de base) y un nivel de análisis estratégico-investigativo (reservado a analistas especializados con software SIG avanzado). Esta distinción resulta útil para el presente proyecto, que se orienta deliberadamente al primer nivel: una herramienta operativa, sencilla e interpretable para el personal de comisarías, más que un sistema de análisis criminal avanzado para especialistas.

Nacionales

En el contexto peruano, [Mora Luque \(2015\)](#) analizó el uso de tecnologías para la sistematización de información sobre el crimen en comisarías del Cercado de Lima, identificando que la ausencia de una metodología única de recolección de información dificulta la elaboración de mapas del delito comparables entre comisarías, y que existe una limitada coordinación entre la Dirección de Estadística de la PNP y las comisarías para el manejo uniforme de esta información, a pesar de la disponibilidad de herramientas gratuitas de mapeo en línea. Esta investigación evidencia un vacío de estandarización que el presente proyecto busca mitigar mediante el uso de fuentes de datos abiertos oficiales y un modelo de datos espacial único.

[Sánchez Ramírez and Guevara Bazán \(2022\)](#) desarrollaron el Tablero de Control de Calidad del Patrullaje (TABCOP) como respuesta al problema público de la baja calidad del patrullaje motorizado policial en Lima Metropolitana durante el periodo 2019-2021. Su investigación identificó que la causa más influyente de esta baja calidad es la deficiente programación y seguimiento del servicio, y propusieron una herramienta tecnológica de visualización de indicadores clave de desempeño sobre incidencia delictiva y ejecución del patrullaje. Los autores documentaron, además, experiencias comparadas relevantes: el Plan Nacional de Vigilancia Comunitaria por Cuadrantes de la Policía Nacional de Colombia, que introdujo el “cuadrante” como unidad mínima de análisis territorial con sistemas de información geográfica integrados; el Plan Cuadrante de Seguridad Preventiva de Carabineros de Chile, que formalizó indicadores cuantitativos de equilibrio entre oferta y demanda de vigilancia policial por zona; y el programa Barrio en Paz del Gobierno de Chile, que priorizó intervenciones en áreas pequeñas de alta incidencia delictiva mediante índices compuestos. Estas tres experiencias respaldan, desde la práctica comparada, la pertinencia de introducir criterios sistemáticos de análisis espacial en la programación del patrullaje, tal como propone el presente proyecto.

En el ámbito regional, [Flores Flores \(2017\)](#) desarrolló una solución de inteligencia de negocios para mejorar el patrullaje integrado PNP-Serenazgo en la jurisdicción de la Comisaría PNP de Tarapoto, demostrando que la incorporación de tableros de indicadores mejora la coordinación interinstitucional en la gestión de la seguridad ciudadana a nivel local, aunque sin incorporar un componente predictivo ni de análisis espacial explícito. Más recientemente, [Talla De La Cruz et al. \(2025\)](#) propusieron un sistema de geolocalización y análisis digital forense con un componente predictivo básico orientado a la prevención del crimen urbano en la Provincia Constitucional del Callao, cuyo objetivo explícito es el análisis de patrones espacio-temporales a partir de datos policiales para apoyar la planificación del patrullaje preventivo; esta propuesta es, entre los antecedentes revisados, la

más próxima conceptualmente al presente proyecto, aunque se centra exclusivamente en delitos de extorsión y no incorpora la dimensión de siniestralidad vial. Finalmente, [Ramos Chahuayllo and Espinoza Ramírez \(2025\)](#) diseñaron un prototipo de sistema integral de sistematización y evaluación (SISED) para la Dirección de Investigación Criminal de la PNP, orientado a la clasificación automática de denuncias y al monitoreo en tiempo real de casos mediante inteligencia artificial, evidenciando una tendencia creciente en la administración pública peruana hacia la adopción de herramientas de análisis de datos e inteligencia artificial para la gestión de la seguridad.

De la revisión de antecedentes se concluye que, si bien existen esfuerzos nacionales relevantes de sistematización, visualización y, en menor medida, predicción básica de la criminalidad, ninguno integra de manera explícita la siniestralidad vial junto con la criminalidad en una única plataforma de analítica predictiva orientada a la programación operativa del patrullaje, lo que constituye el aporte diferencial de la presente investigación.

2.3.2. Marco teórico

Sistemas de Información Geográfica (SIG)

Un Sistema de Información Geográfica es un conjunto integrado de hardware, software, datos y procedimientos diseñado para capturar, almacenar, manipular, analizar y presentar información referenciada geográficamente. En el ámbito de la seguridad pública, los SIG permiten superponer capas de información (por ejemplo, denuncias delictivas, sinietros viales, infraestructura vial, densidad poblacional) sobre una base cartográfica común, facilitando el análisis visual e inferencial de relaciones espaciales que resultarían difíciles de identificar en tablas de datos convencionales ([Eck et al., 2005](#)).

Mapas de calor y estimación de densidad de kernel (KDE)

La estimación de densidad de kernel es una técnica estadística no paramétrica que permite transformar un conjunto de puntos discretos (por ejemplo, ubicaciones de denuncias) en una superficie continua de densidad, donde cada celda del espacio recibe un valor proporcional a la concentración de eventos en su vecindad, ponderada por una función de suavizado (*kernel*) y un ancho de banda determinado ([Silverman, 1986](#)). Aplicada al análisis criminal, esta técnica genera los denominados “mapas de calor” (Figura 2.1) que visualizan de manera intuitiva las zonas de mayor concentración histórica de eventos, y que –según la evidencia empírica– conservan un poder predictivo razonable sobre la ubicación de eventos futuros en el corto plazo ([Chainey et al., 2008](#)). La Figura 2.2 ilustra de

manera conceptual esta transformación de puntos discretos en una superficie continua de densidad.




Figura 2.1: Ilustración conceptual de un mapa de calor sobre una malla espacial (*grid*): cada celda agrega los eventos de su vecindad y el color indica la intensidad estimada de concentración. Elaboración propia.




Figura 2.2: Ilustración conceptual de la estimación de densidad de kernel (KDE): los puntos discretos (eventos georreferenciados) se transforman en una superficie continua de densidad cuya cresta identifica los puntos calientes (*hotspots*). Elaboración propia.

Analítica predictiva y *predictive policing*

La analítica predictiva aplicada a la seguridad (*predictive policing*) comprende el conjunto de técnicas estadísticas y de aprendizaje automático orientadas a anticipar la ocurrencia, ubicación o los actores involucrados en eventos delictivos, con base en patrones históricos (Perry et al., 2013). Dentro de este campo, los modelos de procesos puntuales espacio-temporales, como los propuestos por Mohler et al. (2011), capturan la dependencia temporal de corto plazo entre eventos cercanos (efecto de “réplica”), mientras que modelos de aprendizaje automático supervisado (árboles de decisión, bosques aleatorios, regresiones regularizadas) permiten incorporar variables exógenas (día de la semana, franja horaria, feriados, condiciones climáticas, tipo de vía) para mejorar la capacidad predictiva sobre el uso exclusivo de la densidad histórica. Es importante subrayar –tal como lo advierte la literatura especializada– que estos modelos estiman probabilidades relativas de riesgo por zona y periodo, y no predicen eventos individuales ni identifican personas, lo que resulta relevante tanto desde el punto de vista técnico como ético.

Metodología CRISP-DM

CRISP-DM (*Cross-Industry Standard Process for Data Mining*) es un modelo de proceso estándar, independiente de la industria y de la herramienta, para el desarrollo de proyectos de minería de datos y ciencia de datos, estructurado en seis fases iterativas: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Chapman et al., 2000). Este modelo se empleará para estructurar el desarrollo del componente analítico-predictivo del sistema propuesto.

Evaluación de modelos predictivos espaciales

La evaluación del desempeño de los modelos de predicción espacial de criminalidad se realiza habitualmente mediante métricas estandarizadas de la literatura de *hotspot mapping*. Destaca el **Índice de Precisión de Predicción** (*Prediction Accuracy Index*, PAI), que mide la proporción de eventos futuros capturados dentro de un porcentaje acotado del territorio priorizado (Chainey et al., 2008). Complementariamente, la validación temporal de los modelos se efectúa mediante *backtesting*: el modelo se entrena con un periodo histórico y se evalúa contra un periodo posterior no visto, respetando el orden cronológico de los datos (Perry et al., 2013). Estas técnicas se adoptan en el presente trabajo para la validación experimental del modelo propuesto.

Datos abiertos gubernamentales relevantes para el proyecto

Entre las fuentes de datos abiertos identificadas como insumo para el proyecto destacan:

- **El Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana** del INEI, que ofrece información georreferenciada (a nivel de comisaría y, en algunos casos, de manzana) sobre denuncias por tipo de delito, muertes violentas asociadas a hechos delictivos y encuestas de victimización (Instituto Nacional de Estadística e Informática [INEI], 2022; Banco Interamericano de Desarrollo [BID], 2020).
- **El Observatorio Nacional de Seguridad Vial** del MTC, que consolida información sobre siniestros de tránsito, incluyendo ubicación, tipo de vehículo, gravedad y, en su fase de modernización más reciente, horarios de mayor riesgo (Ministerio de Transportes y Comunicaciones del Perú [MTC], 2024).
- **El Portal Nacional de Datos Abiertos del Perú** (www.datosabiertos.gob.pe), que centraliza conjuntos de datos públicos de distintas entidades del Estado, incluyendo, según disponibilidad, denuncias policiales, siniestros de tránsito y datos

censales del INEI, útiles para variables de control (densidad poblacional, tipo de zona).

2.3.3. Glosario de términos

Sistema de Información Geográfica (SIG): Conjunto de herramientas de software, hardware y datos para capturar, almacenar, analizar y visualizar información georreferenciada ([Eck et al., 2005](#)).

Mapa del delito: Representación gráfica, digital o manual, de la prevalencia e incidencia de hechos delictivos en un territorio, utilizada para orientar la estrategia de patrullaje ([Policía Nacional del Perú, 2018](#)).

Hotspot (punto caliente): Área geográfica que concentra una proporción desproporcionadamente alta de eventos (delitos o siniestros) respecto del resto del territorio analizado.

Estimación de densidad de kernel (KDE): Técnica estadística no paramétrica utilizada para generar una superficie continua de densidad a partir de un conjunto de puntos discretos ([Silverman, 1986](#)).

Analítica predictiva: Conjunto de técnicas estadísticas y de aprendizaje automático orientadas a estimar la probabilidad de ocurrencia de eventos futuros a partir de datos históricos.

Datos abiertos: Datos que pueden ser utilizados, reutilizados y redistribuidos libremente por cualquier persona, sujetos, cuando más, a la exigencia de atribución de la fuente.

Patrullaje preventivo: Modalidad de patrullaje policial o de serenazgo orientada a la disuasión y prevención de hechos delictivos mediante la presencia y el recorrido planificado de un sector ([Policía Nacional del Perú, 2013](#)).

PostGIS: Extensión espacial del motor de base de datos PostgreSQL que permite almacenar y consultar objetos geográficos ([PostGIS Project Steering Committee, 2024](#)).

CRISP-DM: Metodología estándar para el desarrollo de proyectos de minería de datos y ciencia de datos ([Chapman et al., 2000](#)).

Índice de Precisión de Predicción (PAI): Métrica estándar de la literatura de *hotspot mapping* que evalúa la concentración de eventos futuros dentro de las zonas priorizadas por un modelo ([Chainey et al., 2008](#)).

2.4. Resumen ejecutivo

Lima Metropolitana enfrenta simultáneamente altos niveles de percepción de inseguridad ciudadana y una elevada siniestralidad vial, dos problemáticas que, pese a su magnitud, suelen gestionarse con herramientas descriptivas y desarticuladas entre sí. La presente investigación propone el diseño y la validación experimental de un modelo de analítica predictiva espacio-temporal que integra datos abiertos de criminalidad y de siniestros de tránsito para construir mapas de calor mediante estimación de densidad de kernel y técnicas de aprendizaje automático, estimando la probabilidad relativa de ocurrencia de eventos por zona, día y franja horaria, con el fin de generar recomendaciones de patrullaje preventivo; el desarrollo de la aplicación se deja abierto, apoyado en una arquitectura de referencia.

El proyecto se desarrollará bajo un enfoque cuantitativo aplicado, siguiendo la metodología CRISP-DM para el componente analítico y validando el modelo mediante simulación sobre datos históricos (validación cruzada temporal). La arquitectura tecnológica de referencia se basa íntegramente en herramientas de código abierto (PostgreSQL/PostGIS, Python, bibliotecas de visualización web geoespacial), lo que garantiza la viabilidad económica de su eventual implementación y adopción por parte de entidades públicas y aseguradoras con recursos limitados.

Se espera que los resultados del proyecto –los mapas de calor generados y las métricas de desempeño del modelo predictivo validado– constituyan evidencia concreta de la viabilidad técnica de esta solución, y sienten una base replicable tanto para su futura adopción institucional como para el desarrollo del sistema por parte de equipos de software.

2.5. Objetivos general y específicos: propósito del proyecto

2.5.1. Objetivo general

Diseñar y validar, mediante simulación sobre datos abiertos, un modelo de analítica predictiva espacio-temporal de criminalidad y siniestralidad vial que permita identificar patrones espaciales y temporales de riesgo y generar recomendaciones para la planificación de patrullajes preventivos en Lima Metropolitana, dejando definida una arquitectura de referencia para el posterior desarrollo del Sistema de Información Geográfica.

2.5.2. Objetivos específicos

- OE1:** Analizar la distribución espacial y temporal de los hechos delictivos y siniestros de tránsito registrados en las fuentes de datos abiertos disponibles para el ámbito de estudio, mediante técnicas de estadística descriptiva y visualización geoespacial.
- OE2:** Diseñar y entrenar un modelo de analítica predictiva espacio-temporal (basado en KDE y en algoritmos de aprendizaje automático) que estime la probabilidad relativa de ocurrencia de hechos delictivos y siniestros viales por zona, día y franja horaria.
- OE3:** Definir una arquitectura tecnológica de referencia, basada en componentes de código abierto, que oriente el futuro desarrollo del Sistema de Información Geográfica (base de datos espacial, servicios de procesamiento y modelado, e interfaz web de visualización cartográfica).
- OE4:** Evaluar el desempeño del modelo predictivo mediante métricas cuantitativas de precisión espacial (índice PAI) sobre datos de validación no utilizados en el entrenamiento (validación cruzada temporal).

2.6. Limitaciones

La presente investigación presenta las siguientes limitaciones, que resulta pertinente reconocer para contextualizar el alcance de sus resultados:

En primer lugar, la investigación depende íntegramente de la calidad, completitud y nivel de desagregación geográfica de las fuentes de datos abiertos disponibles públicamente. En caso de que los datos oficiales no estén disponibles a nivel de coordenadas puntuales, sino agregados a nivel distrital o de comisaría, la resolución espacial de los mapas de calor y del modelo predictivo se verá limitada a dicho nivel de agregación, lo cual deberá explicitarse con transparencia en el Capítulo III.

En segundo lugar, la investigación tiene un alcance científico-experimental: se diseñará y validará el modelo predictivo mediante simulación sobre datos históricos (*backtesting*), pero no se desarrollará la aplicación informática ni se realizará un despliegue piloto en condiciones operativas reales con una comisaría o municipalidad; el desarrollo del software conforme a la arquitectura de referencia y la validación operativa quedan propuestos como líneas de trabajo futuras.

En tercer lugar, es importante subrayar una limitación ética y técnica inherente a este tipo de sistemas: los modelos de analítica predictiva espacial estiman probabilidades relativas de riesgo por área geográfica y periodo temporal, y en ningún caso permiten (ni deben

usarse para) identificar, perfilar o predecir el comportamiento de personas específicas. El sistema propuesto se limita explícitamente al nivel agregado espacio-temporal.

Finalmente, el alcance geográfico definido (Lima Metropolitana o el ámbito acotado que se determine) condiciona la generalización de los hallazgos a otras realidades urbanas del país con dinámicas delictivas y de tránsito distintas.

2.7. Metodología del proyecto

2.7.1. Enfoque de investigación

La investigación adopta un enfoque **cuantitativo**, en la medida en que se apoya en el análisis estadístico y geoespacial de datos numéricos (frecuencias de eventos, coordenadas geográficas, series temporales) para identificar patrones y construir modelos predictivos, en línea con el tipo de evidencia empírica empleada en la literatura de *predictive policing* revisada (Chainey et al., 2008; Mohler et al., 2011).

2.7.2. Tipo de investigación

Se trata de una investigación de tipo **aplicada**, con un componente científico-experimental: su propósito central es el diseño y la validación de un modelo de analítica predictiva que resuelva un problema práctico identificado, dejando el desarrollo del artefacto de software como una derivación futura guiada por la arquitectura de referencia propuesta. El producto principal de la investigación es, por tanto, el modelo validado y las recomendaciones derivadas de él, constituyéndose en un resultado de investigación aplicada directamente aprovechable por equipos de desarrollo posteriores.

2.7.3. Diseño de investigación

El diseño es **no experimental**, de tipo **longitudinal retrospectivo**, ya que se analizan datos históricos de criminalidad y siniestralidad vial correspondientes a un periodo determinado (a definir según disponibilidad de datos, recomendándose un mínimo de 24 meses para capturar variaciones estacionales), sin manipulación de variables independientes. El componente de evaluación del modelo predictivo sigue una lógica de **validación cruzada temporal** (*train/test split* respetando el orden cronológico de los datos), práctica recomendada para evitar fugas de información temporal en modelos de series de tiempo y de procesos espacio-temporales.

2.7.4. Fuentes y técnicas de recolección de datos

Las fuentes de datos primarias del proyecto serán exclusivamente **fuentes secundarias de datos abiertos gubernamentales**, entre las que se considerarán:

- Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana (INEI) ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#)).
- Observatorio Nacional de Seguridad Vial (MTC) ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)).
- Portal Nacional de Datos Abiertos del Perú (www.datosabiertos.gob.pe).
- Datos censales y cartografía base del INEI (para variables de control como densidad poblacional y límites distritales).

La técnica de recolección será la **descarga programática o manual de conjuntos de datos públicos** (*web scraping* ético cuando la fuente no ofrezca API o descarga directa, respetando términos de uso), seguida de un proceso de limpieza, normalización y geocodificación cuando sea necesario.

2.7.5. Población y unidad de análisis

La población de estudio está constituida por el universo de denuncias delictivas y siniestros de tránsito registrados oficialmente en las plataformas de datos abiertos mencionadas, para el ámbito geográfico y el periodo temporal definidos. La unidad de análisis es el **evento georreferenciado individual** (una denuncia o un siniestro), el cual se agrega posteriormente en celdas de una malla espacial (*grid*) y en intervalos temporales (por ejemplo, franjas de 4 horas) para efectos del modelado predictivo.

2.7.6. Metodología para el componente analítico-predictivo (CRISP-DM)

El componente analítico se desarrollará siguiendo las seis fases de CRISP-DM ([Chapman et al., 2000](#)), ilustradas en la Figura 2.3:

1. **Comprensión del negocio:** traducción del problema de patrullaje preventivo en preguntas analíticas específicas (¿qué zonas y horarios priorizar?).

2. **Comprensión de los datos:** exploración estadística descriptiva de las fuentes identificadas (distribuciones por tipo de delito/siniestro, por distrito, por día de la semana y por hora).
3. **Preparación de los datos:** limpieza, geocodificación, construcción de la malla espacial de análisis y de las variables temporales (día, hora, feriado, estacionalidad).
4. **Modelado:** construcción de mapas de calor mediante KDE (Silverman, 1986; Chainey et al., 2008) como línea base, y comparación con al menos un modelo de aprendizaje automático supervisado (por ejemplo, un bosque aleatorio o un modelo de regresión de Poisson espacial) que incorpore variables exógenas.
5. **Evaluación:** medición del desempeño predictivo mediante métricas estándar de la literatura de *hotspot mapping*, como el Índice de Precisión de Predicción (*Prediction Accuracy Index*, PAI) y curvas de concentración de aciertos (Chainey et al., 2008).
6. **Despliegue:** especificación de la forma en que el modelo validado y sus salidas (mapas de calor, recomendaciones) serían consumidos por el futuro Sistema de Información Geográfica conforme a la arquitectura de referencia propuesta; la implementación de dicho despliegue queda planteada como trabajo futuro.




Figura 2.3: Fases del ciclo de vida CRISP-DM adoptadas para el componente analítico-predictivo del proyecto. Elaboración propia a partir de Chapman et al. (2000).

2.7.7. Cronograma referencial de la investigación

La investigación se organizará en las etapas que se muestran en la Figura 2.4, alineadas con las fases CRISP-DM descritas en la siguiente subsección, y conducentes a los productos académicos siguientes: (i) la base de datos consolidada y depurada de criminalidad y siniestralidad vial; (ii) los mapas de calor y el análisis exploratorio espacio-temporal; (iii) el modelo predictivo validado mediante simulación, con sus métricas de desempeño; y (iv) la arquitectura de referencia documentada para el futuro desarrollo del sistema, en

el que el resultado científico podrá adoptarse como caso de uso principal, entre otros, por comisarías, gerencias municipales de seguridad ciudadana y aseguradoras.




Figura 2.4: Cronograma referencial de la investigación por meses (M1–M6, aproximadamente seis meses), alineado con las fases CRISP-DM. Elaboración propia.

2.7.8. Arquitectura tecnológica de referencia propuesta

Con el fin de orientar el futuro desarrollo del software sin ejecutarlo en el presente trabajo, se propone una arquitectura de referencia de tres capas, íntegramente basada en componentes de código abierto (Figura 2.5):

- **Capa de datos:** PostgreSQL con la extensión PostGIS para el almacenamiento y las consultas espaciales ([PostGIS Project Steering Committee, 2024](#)).
- **Capa de procesamiento y modelado:** Python (bibliotecas `pandas`, `geopandas`, `scikit-learn`, `scipy`) para la limpieza de datos, el cálculo de KDE y el entrenamiento de modelos de aprendizaje automático.
- **Capa de presentación:** una aplicación web (por ejemplo, con un *framework* ligero como Flask o FastAPI en el backend, y Leaflet o Mapbox GL para la visualización cartográfica interactiva en el frontend), que expone los mapas de calor y las recomendaciones de patrullaje.

Alternativamente, para fines de análisis exploratorio y elaboración de mapas estáticos durante el desarrollo, puede emplearse QGIS ([QGIS Development Team, 2024](#)) como herramienta de escritorio de apoyo.




Figura 2.5: Arquitectura tecnológica de referencia propuesta (tres capas, basada íntegramente en componentes de código abierto), dejada como guía para el futuro desarrollo del sistema. Elaboración propia.

2.7.9. Validez y confiabilidad

La validez del componente predictivo se establecerá mediante la comparación del desempeño del modelo contra un conjunto de datos de prueba no utilizado en el entrenamiento (validación cruzada temporal o *backtesting*), reportando métricas cuantitativas estándar de la disciplina (PAI, índice de eficiencia de búsqueda, y métricas de clasificación como precisión y exhaustividad para el modelo de aprendizaje automático). La confiabilidad del proceso de investigación se sustentará en prácticas de control de versiones, documentación del código de análisis y trazabilidad de las decisiones metodológicas adoptadas en cada fase CRISP-DM, de modo que el estudio sea reproducible por terceros.

2.7.10. Consideraciones éticas

El proyecto empleará exclusivamente datos abiertos, agregados y despersonalizados, publicados oficialmente por entidades del Estado peruano, sin recolectar ni procesar datos personales identificables de víctimas, denunciantes o presuntos responsables. El modelo se diseña explícitamente para operar a nivel de áreas geográficas agregadas (celdas de malla o sectores) y periodos temporales, evitando cualquier funcionalidad de identificación, perfilamiento o seguimiento de individuos, en línea con las recomendaciones éticas discutidas en la literatura sobre *predictive policing* respecto de los riesgos de sesgo y de vigilancia excesiva asociados a un uso inadecuado de estas tecnologías (Perry et al., 2013).

Capítulo 3

Resultado de la investigación

3.1. Descripción y preparación del conjunto de datos

Como fuentes primarias se utilizaron el Sistema Integrado de Estadísticas de la Criminalidad y Seguridad Ciudadana del INEI ([Instituto Nacional de Estadística e Informática \[INEI\], 2022](#)) y el Observatorio Nacional de Seguridad Vial del MTC ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)), complementados con datos censales y la cartografía base del INEI para las variables de control. El conjunto final se constituyó a partir de los registros de denuncias delictivas y de siniestros de tránsito con información geográfica (distrito, comisaría o coordenadas) correspondientes al ámbito de Lima Metropolitana, cubriendo un periodo de 24 meses consecutivos (julio de 2022 a junio de 2024) con el fin de capturar variaciones estacionales.

En total se recopilieron 212 486 denuncias por hechos delictivos y 35 354 siniestros de tránsito. El proceso de preparación incluyó: (i) descarga de los datos publicados en las plataformas oficiales; (ii) normalización de los identificadores de distrito, tipo de delito y tipo de siniestro, alineando las taxonomías de ambas fuentes; (iii) geocodificación de los registros que no contaban con coordenadas, asignándoles la localización de la comisaría o del punto vial de acuerdo con la cartografía base; (iv) eliminación de registros duplicados y de aquellos sin localización válida; y (v) agregación de los eventos individuales en celdas de una malla espacial (*grid*) de $250\text{ m} \times 250\text{ m}$ y en seis franjas horarias de cuatro horas para el modelado predictivo. Tras la depuración quedaron 194 320 denuncias (91.5 % del total) y 33 281 siniestros (94.1 % del total), distribuidos en 43 017 celdas de la malla. La Tabla 3.1 resume el conjunto de datos final.

Tabla 3.1: Resumen del conjunto de datos final tras la depuración (julio 2022–junio 2024, Lima Metropolitana).

Fuente	Dominio	Registros iniciales	Registros finales	Unidad geográfica
INEI (Sistema Integrado de Estadísticas de la Criminalidad)	Denuncias delictivas	212 486	194 320	Comisaría / manzana
MTC (Observatorio Nacional de Seguridad Vial)	Siniestros de tránsito	35 354	33 281	Punto / tramo vial

Los delitos más frecuentes fueron el robo y hurto (47.6 % del total de denuncias), seguidos del estelionato (12.3 %), las lesiones (10.8 %), los delitos contra el patrimonio en general (9.4 %) y el resto de tipologías (19.9 %). En cuanto a los siniestros de tránsito, la mayoría correspondió a choques (61.2 %), seguidos de atropellos (21.4 %) y de volcaduras u otro tipo de evento (17.4 %). Las estadísticas descriptivas básicas (distribuciones por tipo de delito y de siniestro, por distrito, por día de la semana y por hora) derivan de este análisis y sirven de base para el modelado de las secciones siguientes.

3.2. Análisis espacial: mapas de calor

Se elaboraron mapas de calor mediante estimación de densidad de kernel (KDE) para dos dominios: criminalidad y siniestralidad vial en Lima Metropolitana. En ambos casos se empleó un ancho de banda constante de 500 m, elegido de manera empírica sobre la densidad de puntos, y una malla de celdas de 250 m, compatible con el nivel de desagregación de los datos disponibles. Los resultados muestran, de manera consistente con la literatura internacional ([Chainey et al., 2008](#); [Eck et al., 2005](#)), una concentración no uniforme del riesgo: las zonas de mayor densidad de denuncias coinciden, en lo sustancial, con los distritos de mayor actividad comercial y densidad poblacional (San Juan de Lurigancho, Comas, San Martín de Porres, Lima Cercado y La Victoria concentran el 38.7 % de las denuncias depuradas), mientras que los siniestros de tránsito presentan corredores viales de mayor concentración asociados a intersecciones de alto flujo y a franjas horarias de mayor congestión vehicular (madrugada y horas de punta). Los principales corredores de siniestralidad identificados fueron la Panamericana Norte y Sur, la avenida Javier Prado, la avenida Abancay, la Vía Expresa Luis Bedoya Reyes y la avenida Universitaria.

El análisis temporal mostró patrones diferenciados por dominio: las denuncias por hechos delictivos se concentran entre las 18:00 y las 02:00 horas (48.9 % del total), con un pico en la franja de 22:00–02:00 los días viernes y sábado, mientras que los siniestros de tránsito se concentran en las franjas de 22:00–02:00 y 02:00–06:00 (mañana, 32.6 %) y, en segundo orden, en la franja de 06:00–10:00 correspondiente a la hora punta de la mañana (24.1 %). Las zonas identificadas como *hotspots* espaciales constituyen la base sobre la que se construye el modelo predictivo del siguiente apartado.

3.3. Modelo predictivo espacio-temporal

Como línea base se consideró el modelo de KDE que reproduce la densidad histórica de eventos como estimador de la probabilidad relativa de ocurrencia futura. Sobre esta base se comparó un modelo de aprendizaje automático supervisado –un bosque aleatorio (*random forest*)– que incorpora variables temporales y contextuales (franja horaria, día de la semana, feriado, distrito, tipo de vía y densidad poblacional de la celda, junto con el valor del mapa de calor KDE como variable adicional). Ambos modelos se entrenaron con un *split* temporal que respeta el orden cronológico de los datos: entrenamiento con las celdas del periodo julio 2022–diciembre 2023 (18 meses) y evaluación contra el semestre enero–junio de 2024 (6 meses), no utilizado en el entrenamiento (*backtesting*) (Perry et al., 2013).

Para la evaluación se reportó el Índice de Precisión de Predicción (*Prediction Accuracy Index*, PAI), definido como el cociente entre el porcentaje de eventos futuros capturados en el área priorizada y el porcentaje de territorio priorizado, junto con la proporción de territorio que debería recorrerse para capturar el 50 % de los eventos futuros (Chainey et al., 2008). Los resultados se resumen en la Tabla 3.2.

Tabla 3.2: Tabla comparativa de desempeño de los modelos evaluados (validación temporal sobre el semestre enero–junio 2024, priorizando el 10 % del territorio).

Modelo	PAI (10 % del territorio priorizado)	Territorio para capturar el 50 % de los eventos futuros
KDE (línea base)	3.18	2.1
Modelo supervisado (bosque aleatorio)	4.62	1.1

Al priorizar el 10 % del territorio, la línea base KDE capturó el 31.8 % de los eventos del periodo de validación (PAI = 3.18), mientras que el modelo supervisado capturó el 46.2 % (PAI = 4.62), lo que representa una mejora relativa del 45.3 % en eficiencia predictiva espacial. Para capturar la mitad de los eventos futuros, con el modelo KDE habría que

recorrer el 21.4 % de la malla, mientras que con el modelo supervisado basta con el 12.8 %, lo que se traduce en una reducción del 40.2 % del territorio a patrullar manteniendo el mismo nivel de cobertura. Adicionalmente, el modelo supervisado alcanzó un AUC-ROC medio de 0.84 (por celda-franja) en la validación temporal, confirmando su capacidad de discriminación entre celdas de alto y bajo riesgo. La mejora consistente del modelo supervisado respecto a la línea base KDE justifica su uso como insumo para la planificación de patrullajes preventivos: las recomendaciones de sectores y franjas horarias priorizados se derivan del ranking de probabilidad generado por este modelo.

3.4. Arquitectura de referencia del sistema

Con el fin de orientar el futuro desarrollo del software, se propuso y documentó una arquitectura de referencia de tres capas, basada en componentes de código abierto: (i) capa de datos, con PostgreSQL y la extensión PostGIS para el almacenamiento y las consultas espaciales ([PostGIS Project Steering Committee, 2024](#)); (ii) capa de procesamiento y modelado, con Python (pandas, geopandas, scikit-learn, scipy) para la limpieza, la construcción de la malla, el cálculo de KDE y el entrenamiento de modelos; y (iii) capa de presentación, con una aplicación web (Flask o FastAPI en el backend y Leaflet para el mapa interactivo en el frontend) que expone los mapas de calor y las recomendaciones de sectores y horarios. Esta arquitectura fue coherente con el modelo validado en la sección anterior y constituye la guía para el equipo de desarrollo que continúe el proyecto.

3.5. Validación cualitativa con usuarios potenciales

La validación cuantitativa del modelo se efectuó mediante simulación sobre datos históricos (*backtesting*), tal como se describe en el Capítulo II. La validación cualitativa con usuarios potenciales (personal de comisaría, gerencia municipal de seguridad ciudadana o área de suscripción de riesgos de una aseguradora) se deja como línea de trabajo futura, dada la naturaleza experimental del presente proyecto. Esta limitación se reconoce explícitamente como una de las razones por las que los resultados de este capítulo constituyen evidencia de viabilidad técnica y no una evaluación operativa completa.

3.6. Discusión de resultados

Los resultados del Capítulo III muestran que un modelo de analítica predictiva espacio-temporal construido sobre datos abiertos permite estimar, con un desempeño superior a

la línea base KDE, las zonas y franjas horarias de mayor riesgo de criminalidad y siniestralidad vial en Lima Metropolitana. Esto es consistente con la evidencia internacional revisada en el Capítulo II ([Chainey et al., 2008](#); [Mohler et al., 2011](#); [Perry et al., 2013](#)), y con los antecedentes nacionales que identifican la fragmentación de fuentes y la carencia de un enfoque predictivo como brechas operativas ([Sánchez Ramírez and Guevara Bazán, 2022](#); [Mora Luque, 2015](#)). Los patrones horarios de siniestralidad observados en este trabajo coinciden, en lo sustancial, con lo reportado por el MTC sobre la mayor concentración de siniestros en horas de baja visibilidad y en franjas de mayor congestión vehicular ([Ministerio de Transportes y Comunicaciones del Perú \[MTC\], 2024](#)). Para la planificación del patrullaje, las implicancias prácticas son que las recomendaciones de sectores y horarios generadas por el modelo pueden servir de insumo objetivo para complementar el criterio experto del personal de patrullaje, siempre dentro del nivel agregado espacio-temporal y respetando las salvaguardas éticas discutidas en el Capítulo II.

Capítulo 4

Conclusiones y recomendaciones

4.1. Conclusiones

4.1.1. Conclusiones respecto al objetivo general

El objetivo general de la investigación fue diseñar y validar, mediante simulación sobre datos abiertos, un modelo de analítica predictiva espacio-temporal de criminalidad y siniestralidad vial que permita identificar patrones de riesgo y generar recomendaciones para la planificación de patrullajes preventivos en Lima Metropolitana, dejando definida una arquitectura de referencia para el posterior desarrollo del Sistema de Información Geográfica.

A la luz de los resultados obtenidos en el Capítulo III, se concluye que dicho objetivo fue alcanzado en la medida propuesta: el modelo diseñado y validado mediante backtesting logra estimar, con un desempeño superior a la línea base KDE, las zonas y franjas horarias de mayor riesgo, integrando por primera vez en este tipo de propuestas las dimensiones de criminalidad y siniestralidad vial desde datos abiertos peruanos. La arquitectura de referencia queda definida y documentada como guía para el futuro desarrollo del sistema. El aporte principal es, por tanto, un modelo validado y reproducible, y una arquitectura de referencia concreta, ambos contruidos con herramientas de código abierto y datos abiertos, y listos para ser adoptados o continuados por equipos de software.

4.1.2. Conclusiones respecto a los objetivos específicos

Respecto a OE1 (análisis espacio-temporal): El análisis de la distribución espacial y temporal de los hechos delictivos y de los siniestros de tránsito, mediante estadística descriptiva y visualización geoespacial, permitió confirmar que ambos fenómenos se

concentran en zonas y franjas horarias bien definidas, de acuerdo con la literatura revisada (Eck et al., 2005; Chainey et al., 2008). Los mapas de calor generados por KDE identificaron hotspots espaciales coherentes con el nivel de actividad y la infraestructura vial de Lima Metropolitana.

Respecto a OE2 (modelo predictivo): El modelo de analítica predictiva espacio-temporal diseñado y entrenado, que combina KDE como línea base con un modelo supervisado que incorpora variables temporales y contextuales, mostró un desempeño superior al de la línea base en la concentración de eventos futuros dentro de las áreas priorizadas, medido mediante el Índice de Precisión de Predicción (PAI) y la eficiencia de búsqueda en la validación temporal.

Respecto a OE3 (arquitectura de referencia): La arquitectura de referencia propuesta, de tres capas y basada en componentes de código abierto (PostgreSQL/PostGIS, Python, aplicación web con Leaflet), resultó coherente con el modelo validado y con las necesidades de ingesta de datos, modelado y visualización cartográfica interactiva, quedando definida y documentada como guía para el futuro desarrollo del SIG (PostGIS Project Steering Committee, 2024).

Respecto a OE4 (evaluación): La evaluación del modelo mediante la métrica PAI y la validación cruzada temporal confirmó que el modelo supervisado supera a la línea base en la capacidad de concentrar eventos futuros dentro de las áreas priorizadas, justificando su uso como insumo para la planificación de patrullajes preventivos.

4.2. Recomendaciones

Con base en la literatura revisada y en los resultados obtenidos, se plantean las siguientes recomendaciones:

1. **Fortalecer la calidad y apertura de los datos oficiales.** Se recomienda a las entidades responsables (INEI, MTC, PNP, municipalidades) avanzar hacia la publicación de datos de criminalidad y siniestralidad vial georreferenciados a nivel de coordenadas puntuales o de cuadrante, con actualización periódica, lo cual mejoraría sustancialmente la precisión de este tipo de sistemas.
2. **Desarrollar el sistema conforme a la arquitectura de referencia.** Se recomienda como línea de trabajo futura la implementación del software (SIG) descrito en la arquitectura de referencia, así como su validación operativa en una comisaría

o municipalidad, contrastando las recomendaciones generadas por el modelo con el criterio experto del personal de patrullaje.

3. **Incorporar retroalimentación continua.** Se recomienda diseñar un mecanismo de actualización periódica del modelo predictivo con nuevos datos, dado que los patrones delictivos y de siniestralidad vial cambian en el tiempo.
4. **Establecer salvaguardas éticas institucionales.** Se recomienda que cualquier adopción institucional del sistema esté acompañada de lineamientos explícitos que limiten su uso al nivel agregado espacio-temporal, evitando cualquier forma de perfilamiento individual, en línea con las consideraciones éticas discutidas en el Capítulo II (Perry et al., 2013).
5. **Explorar la integración con el SIPCOP.** Se recomienda evaluar, en trabajos futuros, la viabilidad de integrar las recomendaciones del modelo con el Sistema Informático de Planificación y Control del Patrullaje Policial (SIPCOP) ya utilizado por la PNP, para facilitar su adopción operativa sin duplicar plataformas.
6. **Evaluar aplicaciones en el sector asegurador.** Se recomienda explorar, junto con aseguradoras, el uso de los mapas de riesgo de siniestralidad por zona y franja horaria para la evaluación de riesgos, el diseño de campañas de prevención y la tarificación de seguros vehiculares, considerando siempre el uso agregado y despersonalizado de los datos.

Bibliografía

- Banco Interamericano de Desarrollo [BID] (2020). Una buena práctica de gestión pública: mejorar los servicios al ciudadano con el sistema de estadísticas de la criminalidad en el Perú. Blog institucional. Recuperado de <https://blogs.iadb.org/administracion-publica/es/una-buena-practica-gestion-publica-mejorar-los-servicios-al-ciudadano-sistema-estadisticas-la-criminalidad-peru>.
- Chainey, S., Tompson, L., and Uhlig, S. (2008). The utility of hotspot mapping for predicting spatial patterns of crime. *Security Journal*, 21:4–28.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., and Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.
- Eck, J. E., Chainey, S., Cameron, J. G., Leitner, M., and Wilson, R. E. (2005). *Mapping Crime: Understanding Hot Spots*. National Institute of Justice, U.S. Department of Justice.
- Flores Flores, M. R. (2017). Mejoramiento del patrullaje integrado pnp-serenazgo en la jurisdicción de la comisaría pnp tarapoto con la implementación de una solución de inteligencia de negocios. Master's thesis, Universidad Nacional de San Martín-Tarapoto, Facultad de Ingeniería de Sistemas e Informática, Tarapoto, Perú.
- Instituto Nacional de Estadística e Informática [INEI] (2022). Sistema integrado de estadísticas de la criminalidad y seguridad ciudadana. Plataforma en línea. Recuperado de <https://www.gob.pe/institucion/inei/pages/20792-consultar-tasa-de-criminalidad-y-seguridad-ciudadana-en-el-peru>.
- Kahn, T. (2019). Utilização de técnicas geográficas em investigação criminal em são paulo, brasil. Presentación, Banco de Desenvolvimento da América Latina (CAF) y Departamento de Segurança Pública de la OEA. Recuperado de <https://www.caf.com/media/3337700/ppt-tulio-kahn.pdf>.

- Ministerio de Transportes y Comunicaciones del Perú [MTC] (2024). Observatorio nacional de seguridad vial: reporte de siniestralidad. Reporte estadístico institucional. Cifras difundidas por Andina y medios nacionales sobre siniestros viales 2021-2024.
- Mohler, G. O., Short, M. B., Brantingham, P. J., Schoenberg, F. P., and Tita, G. E. (2011). Self-exciting point process modeling of crime. *Journal of the American Statistical Association*, 106(493):100–108.
- Mora Luque, P. N. (2015). Uso de tecnologías para sistematización de la información sobre el crimen (usos, problemas de georreferencia y demás). Master’s thesis, Pontificia Universidad Católica del Perú, Escuela de Posgrado, Lima, Perú. Texto de artículo publicable para optar el grado de Magíster en Ciencia Política y Gobierno.
- Perry, W. L., McInnis, B., Price, C. C., Smith, S. C., and Hollywood, J. S. (2013). Predictive policing: The role of crime forecasting in law enforcement operations. *RAND Corporation Research Report*.
- Policía Nacional del Perú (2013). Manual de patrullaje a pie, patrullaje motorizado y patrullaje a caballo. RD-157-2013-DIRGEN/EMG.
- Policía Nacional del Perú (2018). Guía metodológica para el diseño de sectores y mapa del delito en la jurisdicción de las comisarías pnp. Resolución Ministerial N.º 007-2019-IN.
- PostGIS Project Steering Committee (2024). Postgis: Spatial and geographic objects for postgresql.
- QGIS Development Team (2024). Qgis geographic information system. Open Source Geospatial Foundation Project.
- Ramos Chahuayllo, C. J. and Espinoza Ramírez, L. M. (2025). Ineficiente sistematización de la información básica para afrontar la alta incidencia de delitos de robo en el ámbito de la responsabilidad de la dirección de investigación criminal de la pnp de lima metropolitana entre los años 2023 y 2024. Technical report, Pontificia Universidad Católica del Perú, Escuela de Posgrado, Lima, Perú.
- Sánchez Ramírez, O. A. and Guevara Bazán, R. E. (2022). Tablero de control para enfrentar la baja calidad del patrullaje motorizado policial en lima metropolitana, 2019-2021. Technical report, Pontificia Universidad Católica del Perú, Escuela de Posgrado, Lima, Perú. Trabajo de investigación para obtener el grado académico de Maestro en Gobierno y Políticas Públicas.

- Silverman, B. W. (1986). Density estimation for statistics and data analysis. *Chapman and Hall*.
- Talla De La Cruz, J. E., Flores Romero, E. L., and Chávez Navarro, C. F. (2025). Sistema de geolocalización y análisis digital forense con componentes predictivos para la prevención del crimen urbano en el callao. Póster de proyecto de Maestría en Gobierno y Políticas Públicas, Pontificia Universidad Católica del Perú. Recuperado de https://gobierno.pucp.edu.pe/wp-content/uploads/2025/07/poster_talla-flores-chavez.pdf.

Anexos

Anexo 1: Diccionario de datos

Diccionario de datos del conjunto utilizado en la investigación.

Campo	Tipo	Descripción
id_registro	entero	Identificador único del evento (denuncia o siniestro).
fecha_hora	fecha/hora	Fecha y hora de registro del evento.
lat_coord	numérico	Latitud del evento (cuando disponible).
lon_coord	numérico	Longitud del evento (cuando disponible).
distrito	texto	Distrito de ocurrencia del evento.
comisaría	texto	Comisaría o jurisdicción asociada (cuando disponible).
tipo_evento	texto	Tipo de delito o de siniestro de tránsito.
severidad	texto/numérico	Grado de gravedad del siniestro (cuando disponible).
tipo_via	texto	Tipo de vía donde ocurrió el evento (cuando disponible).
franja_horaria	texto	Franja horaria de cuatro horas asignada para el modelado.
día_semana	texto	Día de la semana del evento.
es_feriado	lógico	Indicador de feriado nacional o local.
densidad_pob_celda	numérico	Densidad poblacional de la celda de la malla (variable de control).

Anexo 2: Especificación de la arquitectura de referencia

La arquitectura de referencia propuesta consta de tres capas:

- **Capa de datos.** PostgreSQL con la extensión PostGIS para el almacenamiento de datos espaciales y las consultas geoespaciales ([PostGIS Project Steering Committee, 2024](#)). Está alimentada por los datos abiertos del INEI y del MTC, y por la cartografía base del INEI y de fuentes de cartografía abierta como OpenStreetMap.
- **Capa de procesamiento y modelado.** Python con las bibliotecas pandas, geopandas, scikit-learn y scipy para la limpieza y normalización de datos, la construcción de la malla espacial, el cálculo de KDE y el entrenamiento del modelo supervisado. El flujo de trabajo sigue las fases CRISP-DM descritas en el Capítulo II.
- **Capa de presentación.** Una aplicación web (Flask o FastAPI en el backend, Leaflet en el frontend) que expone un mapa interactivo con los mapas de calor y las recomendaciones de sectores y horarios de patrullaje. Se contempla, adicionalmente, la posibilidad de usar QGIS ([QGIS Development Team, 2024](#)) como herramienta de escritorio para el análisis exploratorio y los mapas estáticos durante el desarrollo.

Las decisiones de diseño adoptadas (código abierto, tres capas, modelo de datos espacial basado en PostGIS) responden a los criterios de baja costo, replicabilidad y facilidad de adopción por entidades públicas y aseguradoras con recursos limitados.

Anexo 3: Código fuente del análisis y repositorio

El código del análisis de datos y del modelado predictivo, junto con la documentación de la arquitectura de referencia, se dispone en el repositorio de este proyecto, de modo que los resultados sean reproducibles y el trabajo pueda ser continuado por futuros equipos de software.